


Deconvolução e denoising de imagens de simuladas galáxias


Henrique Uhlmann Gobbi - 334932
INF01046 2023/2

Introdução

- Em astronomia, imagens de diferentes espectros da radiação eletromagnética sempre foram um componente essencial dessa ciência;
- Imagens astronômicas sofrem de deformações pelos instrumentos ópticos ou até pela atmosfera, comprometendo a qualidade das medidas;
- Em se tratando de galáxias, a forma dessas é essencial para o estudo da estrutura do cosmos, com importantes pistas sobre as concentrações de matéria escura e visível no nosso universo.



Crédito: Nasa



Crédito: Wikipédia

Introdução

- Em telescópios terrestres, a atmosfera e o próprio sistema óptico do telescópio contribuem para a deformação das imagens, além da adição de ruído;
- Grandes surveys de galáxias produzem imensas quantidades de imagens, que precisam ser processadas para podermos fazer boas medidas;
- Neste trabalho, o modelo do novo telescópio do Observatório Vera C. Rubin (LSST) foi usado para produzir as imagens.



Crédito: Astronomy Magazine

Simulando imagens de galáxias

- As imagens originais de galáxias foram retiradas do dataset COSMOS, contendo imagens do Telescópio Espacial Hubble;
- A ideia é aplicar uma convolução de uma PSF produzida com dados ópticos e atmosféricos do LSST, obtendo a mesma galáxias como ela seria observada por aquele telescópio;
- Além disso, é adicionado ruído do CCD do telescópio e da atmosfera;
- A imagem foi redimensionada para os tamanhos de um survey do LSST (48x48 pixels);
- Tais procedimentos foram realizados com o simulador Galsim, em Python.




Imagem original (ground truth)

->


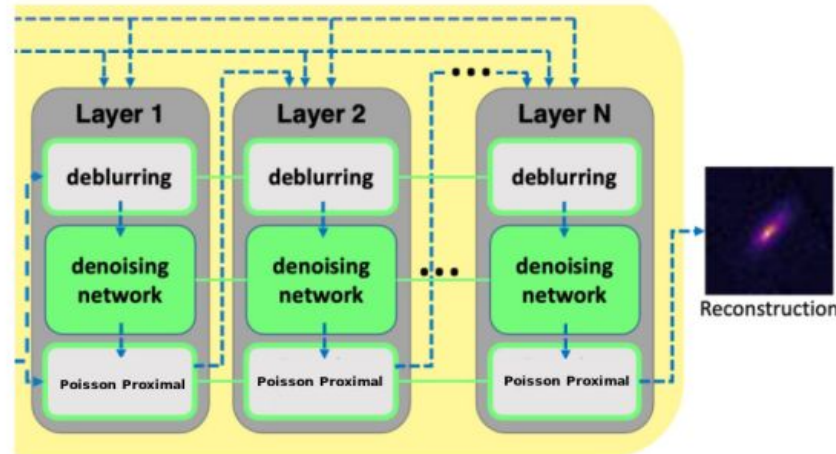


Imagem distorcida pelo LSST

Visão geral da técnica implementada


- O problema de deconvolução de imagens já é muito bem estudado;
- O presente trabalho implementa uma técnica que junta denoising com deblurring, visando remover as distorções do sistema óptico do telescópio e da atmosfera;



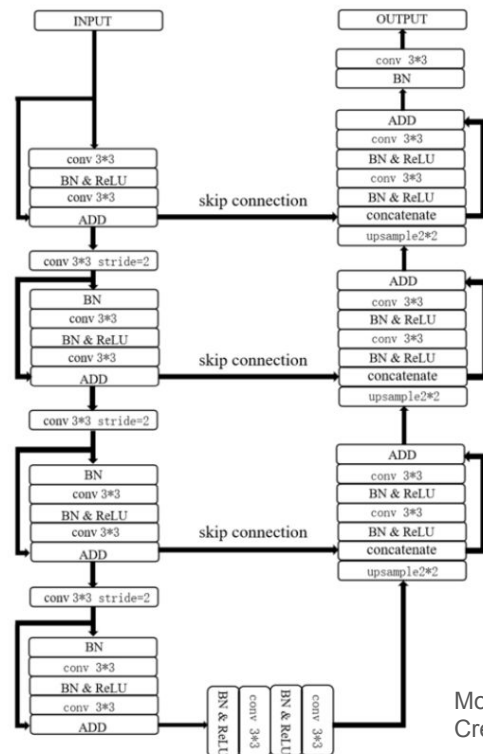
Crédito: Li & Alexander (2023)

ReSUNet para Denoising

- Para realizar a operação de denoising, uma rede neural residual convolucional foi implementada, utilizando o Keras;
- O treinamento ocorreu com imagens apenas com a adição de ruído.



Bloco da rede neural residual.
Crédito: Quian et al. (2022)



Modelo da ResUNet.
Crédito: Quian et al. (2022)

Unrolled PnP ADMM

- Algoritmo de otimização, muito utilizado em processos de deconvolução não-cega;
- Quebra problema maior em subproblemas menores e mais tratáveis.


Algorithm 2 Pseudocódigo do algoritmo Unrolled PnP ADMM de deconvolução, onde H é a matriz de convolução de h .

```
1: Input: Blurred and Noisy Image  $y$ , kernel  $h$ , denoiser  $D$ 
2: Output: Reconstructed Image  $x_K$ 
3: Initialization:
4:   Initialize  $x_0$  using Wiener Filter
5:    $z_0 \leftarrow x_0, v_0 \leftarrow y, u_0^1 \leftarrow 0, u_0^2 \leftarrow 0$ 
6: for  $k = 1, 2, \dots, K$  do
7:   Update  $x_k$ 
8:   Update  $z_k$  using  $D$ 
9:   Update  $v_k$ 
10:   $u_k^1 \leftarrow u_{k-1} + x_k - z_k$ 
11:   $u_k^2 \leftarrow u_{k-1} + Hx_k - v_k$ 
12: end for
13: Output:  $x_K$ 
```


D é a rede neural de denoising,

Resultados Denoising


ResUNet




(a) Imagem de entrada.




(a) Imagem de entrada.




(b) Ground truth



(b) Ground truth




(c) Imagem com remoção de ruído.




(c) Imagem com remoção de ruído.

Resultados Deconvolução


Unrolled PnP ADMM




(a) Imagem de entrada.




(b) Ground truth




(c) Imagem com deconvolução e remoção de ruído.



(a) Imagem de entrada.



(b) Ground truth



(c) Imagem com deconvolução e remoção de ruído.

Conclusões e futuro trabalho

- Os resultados do denoiser foram muito satisfatórios e interessantes, produzindo imagens de qualidade;
- Os resultados da deconvolução foram satisfatórios, embora tenham surgido alguns artefatos de ruído periódico;
- O principal objetivo, que era reconstruir o formato da galáxia, foi cumprido;
- Será interessante investigar a técnica em que a rede de denoising aprende junto com a deconvolução, que já se mostrou muito efetiva em outros estudos;
- Além disso, é interessante implementar uma rede neural para estimar os hiperparâmetros do algoritmo de deconvolução.

Referências

- LSST 2022, LSST Documentation, <https://smtn-002.lsst.io>
- Li T., Alexander E., 2023, Monthly Notices of the Royal Astronomical Society: Letters, 522, L31
- Mandelbaum R., Hirata C. M., Leauthaud A., Massey R. J., Rhodes J., 2012, [Monthly Notices of the Royal Astronomical Society](#), 420, 1518
- Mandelbaum R., et al., 2014, [Astrophysical Journal, Supplement Series](#), 212
- Qian H., Wang X., Chen X., Yang Z., 2022, [Energies](#), 15
- Rowe B., et al., 2015, [Astronomy and Computing](#), 10, 121
- Sanghvi Y., Gnanasambandam A., Chan S. H., 2022, [IEEE Transactions on Computational Imaging](#), 8, 851