

Deconvolução e denoising de imagens simuladas de galáxias

Henrique Uhlmann Gobbi,^{1*}

¹*UFRGS Instituto de Informática, Porto Alegre, Rio Grande do Sul, Brasil*

Accepted 2024. Received 2024; in original form 2024

ABSTRACT

In order to improve the measurement of galaxy shapes, it is essential to use techniques capable of removing optical and atmospheric blurring, as well as atmospheric and imaging equipment noise. Through deconvolution and denoising based on the Alternating Direction Method of Multipliers (ADMM) aided by a convolutional neural network, this study demonstrates a technique to perform such operations, achieving positive results for different levels of signal to noise ratios.

Key words: deconvolution – denoising – galaxy – image processing

1 INTRODUÇÃO

Em imagens astronômicas obtidas por meio de telescópios com base no solo, é comum a ocorrência de deformações decorridas da atmosfera, ou mesmo do sistema óptico do telescópio. Não só isso, mas também o ruído decorrente da atmosfera e do equipamento de CCD também contribuem para a piora das observações. Tais deformações degradam a qualidade da imagem, assim como afetam negativamente as medidas físicas da imagem. Uma importante medida é o formato da galáxia, essencial no estudo de lentes gravitacionais, que, por sua vez, é fundamental para a compreensão da estrutura do universo e a com a quantidade de matéria escura e visível que permeia a estrutura do cosmos. Além disso, a massiva quantidade de dados astronômicos demanda o surgimento de novas técnicas computacionais de processamento desses dados, visando, portanto, melhorar a qualidade das nossas observações.

Normalmente, tais deformações são modeladas por uma convolução com um kernel de borrimento, chamado Point Spread Function (PSF), seguido da adição de ruído. Para restaurar a imagem original e remover tais intempéries, diversos algoritmos e métodos já foram implementados, tanto em imagens comuns como em imagens astronômicas. Com o surgimento, nos últimos anos, das redes neurais convolucionais, novas técnicas para realizar tais procedimentos com base nessa tecnologia surgiram, mostrando resultados impressionantes.

No presente trabalho, é implementada uma técnica que, com base na PSF simulada utilizando parâmetros ópticos do novo Observatório Vera C. Rubin (LSST) e atmosféricos do local do telescópio, uma imagem simulada do LSST distorcida e com ruído de uma galáxia é restaurada para seu formato original, desfazendo, portanto, a adição de ruído e a convolução com o PSF de borrimento. A remoção de ruído foi realizada por uma rede neural convolucional, enquanto que o desborramento foi feito pelo algoritmo PnP ADMM. As duas técnicas foram com-

binadas em uma só, similar ao que foi feito em [Li & Alexander \(2023\)](#).

2 METODOLOGIA

As técnicas propostas neste trabalho podem ser divididas em três partes: simulando imagens de galáxias [2.1](#); removendo ruído com uma CNN [2.2](#) e removendo borrimento e ruído com PnP ADMM [2.3](#).

2.1 Simulando imagens de galáxias

Para simular as imagens das galáxias, foi utilizado o simulador Galsim [Rowe et al. \(2015\)](#), por meio do qual imagens originais de galáxias, do dataset COSMOS tiradas pelo telescópio espacial Hubble, foram modificadas para simular as condições de visualização do LSST, tanto atmosféricas quanto ópticas. As condições para tais atributos foram retiradas de [Mandelbaum et al. \(2014\)](#).

Assim, foi construído um conjunto de imagens de galáxias compostas pela imagem original (ground truth) e a imagem distorcida pelas condições do LSST. A imagem original, do dataset COSMOS, tirada pelo Hubble, que, como sendo um telescópio espacial, não possui ruído nem distorções atmosféricas, com distorções ópticas mínimas, é, portanto, uma ótima imagem de referência. A imagem distorcida é a mesma galáxia, mas como ela seria observada a partir do LSST, com distorções ópticas do telescópio e atmosféricas do local.

Para simular as distorções das imagens, foi utilizado um PSF óptico, criado com as informações dos sistemas ópticos do LSST, com um PSF atmosférico, criado com as informações atmosféricas do local e, por fim, com a adição de ruído, tanto da atmosfera, simulado por ruído Gaussiano, como do sistema de CCD. Foram utilizados valores de sinal-para-ruído de 100 e 40. Um exemplo básico do processo está em [1](#). A PSF descreve como uma fonte de luz pontual é observada por um sistema

* E-mail: hugobbi@inf.ufrgs.br

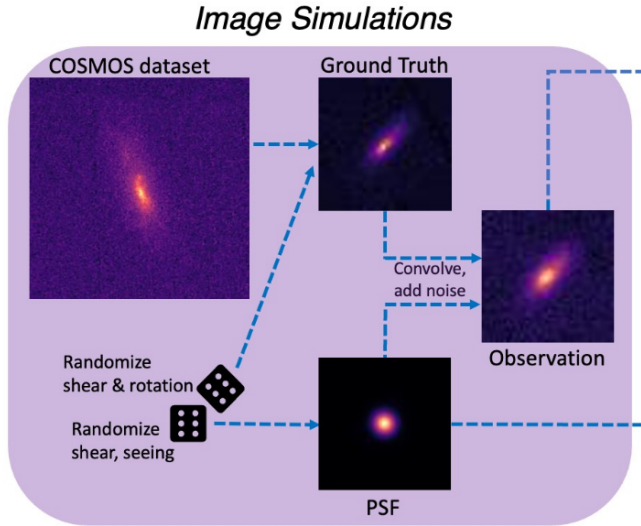


Figure 1. Representação de uma imagem do dataset COSMOS, assim como as imagens simuladas resultantes Li & Alexander (2023).

óptico em um dado instante. Na literatura, a convolução de uma imagem com o PSF dos instrumentos ópticos que a registrou é muito comum para representar borrramento e como uma imagem seria observada por determinado sistema óptico, como em Mandelbaum et al. (2012).

2.2 Denoising por Rede Neural

A remoção de ruído das imagens de galáxias foi realizada a partir de uma rede neural convolucional residual, mais especificamente a ResUNet Qian et al. (2022). Essa rede foi apenas treinada em imagens simuladas de galáxias com a adição de ruído, sem as modificações ópticas ou atmosféricas. A principal ideia desta rede é servir como uma parte do algoritmo de deconvolução.

Uma rede neural residual se baseia no princípio de, em cada bloco residual, enviar o conteúdo da entrada do bloco para ser adicionado ao final do bloco, como mostra a figura 2. Isso ajuda com o poder de abstração de dados da rede, assim como com o problema de gradiente evanescente. Além disso, a rede neural é convolucional, isso significa que possui camadas profundas compostas por operações de convolução com algum kernel cujos pesos são aprendidos pela rede neural durante o aprendizado, sendo atualizados pelo algoritmo de backtracking. A função de perda utilizada neste trabalho foi a do erro quadrático médio (mse).

2.3 Deblurring e denoising com ADMM auxiliado por Rede Neural

Nesta etapa do processo, tudo é unido para produzir o resultado final. Neste trabalho, foi utilizada a técnica Unrolled Plug-and-Play ADMM, demonstrada em Li & Alexander (2023); Sanghvi et al. (2022), com certas modificações devido ao escopo do projeto.

O algoritmo de ADMM é, em sua essência, um algoritmo de otimização. Pode ser usado para resolver problemas convexos que podem ser formulados como a soma de duas funções convexas. É baseado em quebrar um problema em subproblemas




Figure 2. Representação de bloco residual Qian et al. (2022).





Figure 3. Representação simplificada das iterações do algoritmo Unrolled PnP ADMM. Li & Alexander (2023).

menores, mais fáceis de resolver e é muito utilizado em problemas de deconvolução não-cega, em que precisamos estimar uma imagem original x a partir de uma observação y e um kernel de distorção h . Para o caso deste trabalho, é tratada a deconvolução não-cega, já que o PSF de borrimento da imagem da galáxia é utilizado para realizar o processo de deconvolução. Este é um kernel que pode ser estimado com certo grau de precisão em casos reais.


A técnica aqui implementada segue o que foi descrito em Li & Alexander (2023); Sanghvi et al. (2022), com algumas mudanças importantes. É uma técnica iterativa, podendo ser realizada por quantas iterações for necessário até a convergência do resultado. Além disso, é muito modular, com muitos hiperparâmetros que podem ser ajustados para impactar o resultado de diferentes formas. Além disso, o nome Plug-and-Play do algoritmo vem do fato de ele receber como entrada uma rede neural, já treinada, para realizar o denoising da imagem. Esta rede será parte de uma das três etapas principais do algoritmo a cada iteração, realizando a redução de ruído das imagens de cada iteração do algoritmo, como demonstrado pela figura 3. Mais detalhes sobre o algoritmo são encontrados na sessão 3.

3 IMPLEMENTAÇÃO


O trabalho foi desenvolvido com a linguagem Python (3.10), principalmente por conta do suporte ao desenvolvimento de redes neurais. Neste trabalho, foi utilizado o pacote TensorFlow Keras para criar e treinar as redes neurais no ambiente



(a) Imagem de entrada.



(b) Ground truth



(c) Imagem com remoção de ruído.

Figure 5. Resultado da remoção de ruído com razão sinal-para-ruído de 100.


com a adição de ruído atmosférico, modelado por uma Gaussiana e ruído do equipamento de CCD 5 e 6.

4.2 Deconvolução e remoção de ruído


Para a deconvolução, foram utilizados todos os elementos desenvolvidos neste trabalho. Desde a geração das imagens com todas as deformações até o algoritmo ADMM. Os resultados podem ser vistos em 7 e 8.

Nota-se que a rede ResUNet obteve um resultado muito satisfatório, conseguindo inclusive, em algumas ocasiões, superar a qualidade da imagem original. Ainda assim, ao utilizar um ruído mais forte, a rede tem certos problemas para reconstruir a imagem, ainda assim, consegue fazê-lo muito satisfatoriamente.


Para o caso da deconvolução, nota-se que o algoritmo conseguiu reconstruir a forma original da galáxia, o que é bastante positivo. Ainda assim, é possível notar alguns artefatos periódicos



(a) Imagem de entrada.



(b) Ground truth




(c) Imagem com remoção de ruído.

Figure 6. Resultado da remoção de ruído com razão sinal-para-ruído de 40.


cos que surgiram durante o processo de reconstrução, afetando a qualidade da imagem.

5 CONCLUSÕES


O processo de reconstrução de imagens de galáxias é fundamental para o estudo da forma dessas estruturas astronômicas, que nos dão importantes pistas sobre a estrutura geral do universo. Neste trabalho, foi implementada uma técnica para não só corrigir imagens de galáxias deformadas por efeitos atmosféricos ou ópticos mas também remover o ruído dessas imagens, causado pela atmosfera e pelo equipamento de imageamento. Dessa forma, por meio do algoritmo Unrolled PnP ADMM, foi realizada a deconvolução e o denoising de imagens de galáxias distorcidas. Os resultados se mostraram positivos e satisfatórios, ainda que há melhorias que podem ser feitas.



(a) Imagem de entrada.



(b) Ground truth



(c) Imagem com deconvolução e remoção de ruído.


Figure 7. Resultado da deconvolução e remoção de ruído com razão sinal-para-ruído de 100 e $n = 1000$.

6 FUTURO TRABALHO


Para futuros trabalhos, seria interessante, assim como foi feito em [Li & Alexander \(2023\)](#); [Sanghvi et al. \(2022\)](#), utilizar o algoritmo ADMM dentro de uma rede neural, de modo que a rede de denoising possa aprender sobre o conjunto de deconvolução enquanto esta está sendo realizada. Além disso, a implementação de uma rede neural para obter os hiperparâmetros para o algoritmo de ADMM também traria um resultado positivo.

REFERENCES


- LSST 2022, LSST Documentation, <https://smtn-002.lsst.io>
 Li T., Alexander E., 2023, Monthly Notices of the Royal Astronomical Society: Letters, 522, L31
 Mandelbaum R., Hirata C. M., Leauthaud A., Massey R. J., Rhodes



(a) Imagem de entrada.



(b) Ground truth



(c) Imagem com deconvolução e remoção de ruído.

Figure 8. Resultado da deconvolução e remoção de ruído com razão sinal-para-ruído de 100 e $n = 1000$.

- J., 2012, *Monthly Notices of the Royal Astronomical Society*, 420, 1518
 Mandelbaum R., et al., 2014, *Astrophysical Journal, Supplement Series*, 212
 Qian H., Wang X., Chen X., Yang Z., 2022, *Energies*, 15
 Rowe B., et al., 2015, *Astronomy and Computing*, 10, 121
 Sanghvi Y., Gnanasambandam A., Chan S. H., 2022, *IEEE Transactions on Computational Imaging*, 8, 851

This paper has been typeset from a \LaTeX file prepared by the author.